



Food Delivery Times Performance Analysis

Yumita



 **CONCLUSION &
RECOMENDATION**

INTRODUCTION 

 **DASHBOARD
ANALYSIS OUTPUT**

**OVERVIEW
PROJECT** 

 **DATA
PREPROCESSING
& EDA**

**MAIN
PROJECT** 

 **DATA
UNDERSTANDING**

**PROBLEM
STATEMENT** 



INTRODUCTION

Saya memiliki ketertarikan pada **bidang data** dan tujuan karier saya sebagai **Data Analyst**

PENDIDIKAN

- Dibimbing Bootcamp (2026-sekarang)
- S1-S2 Peternakan (2020-2025)

Kontak

Email : yumitaaaaaa@gmail.com

Linkedin : [linkedin.com/in/yumitaa16](https://www.linkedin.com/in/yumitaa16)



YUMITA


OVERVIEW PROJECT

1. DASHBOARD INTERACTIVE

Tujuan : Menganalisis hubungan generasi karyawan terhadap jumlah, performa rating, status aktif, dan jenis klasifikasi kerja untuk efisiensi SDM.

Hasil : Tenaga kerja didominasi Baby Boomers (40%), performa antar generasi setara (2.97\$), dan karyawan muda cenderung memilih kerja tidak tetap.

Rekomendasi : Perusahaan wajib memperkuat strategi rekrutmen generasi muda, meningkatkan stabilitas kerja Gen Z, serta mengoptimalkan transfer pengetahuan.



2. STUDENT BAG PREPROCESSING

Tujuan : Menganalisis pengaruh kombinasi jenis material dan ukuran tas terhadap harga jual produk untuk menemukan nilai ekonomi tertinggi.

Hasil : Data 12.805 baris berhasil dibersihkan dari 6.493 missing value, dan uji Kruskal-Wallis membuktikan distribusi harga tas antar kategori material serta ukuran tergolong stabil dan seragam.

Rekomendasi : Dataset memiliki kombinasi kategori yang seimbang (peluang PMF 8%) sehingga sangat valid dan siap digunakan untuk pemodelan Machine Learning tanpa risiko bias.




OVERVIEW PROJECT

3. STUDENT BAG EDA

Tujuan : Menganalisis pengaruh serta distribusi jenis material dan ukuran tas sekolah terhadap harga jual produk menggunakan metode Exploratory Data Analysis (EDA).

Hasil : Uji statistik Kruskal-Wallis dan visualisasi data membuktikan bahwa jenis material serta ukuran tas terdistribusi merata dan tidak berpengaruh signifikan terhadap harga jual produk.

Rekomendasi : Perusahaan sebaiknya memprioritaskan alokasi produksi pada bahan ekonomis (Polyester/Canvas) serta mengalihkan anggaran ke pengembangan fitur teknologi dan strategi branding modern. .



4. PERFORMA PENJUALAN E-COMMERCE OLIST

Tujuan : Mengoptimalkan kualitas data transaksi e-commerce dengan SQL untuk mengidentifikasi tren omzet, pergeseran kategori terlaris, serta preferensi metode pembayaran konsumen.

Hasil : Penjualan tumbuh stabil dengan puncak tertinggi (peak season) terjadi setiap bulan November, serta didominasi oleh metode pembayaran Credit Card yang mencakup lebih dari 70% total transaksi.

Rekomendasi : Perusahaan sebaiknya memperbanyak kemitraan promosi eksklusif (seperti cicilan 0%) bersama penyedia kartu kredit, sekaligus mempersiapkan infrastruktur logistik 2-3 bulan sebelum lonjakan trafik November.




OVERVIEW PROJECT

5. PROFITABILITY & DISCOUNT IMPACT

Tujuan : Menganalisis pengaruh pemberian diskon terhadap profitabilitas perusahaan serta mengidentifikasi performa profit berdasarkan kategori produk, wilayah, dan segmen pelanggan.

Hasil : Analisis data membuktikan diskon di atas 20% menyebabkan profit terjun bebas ke area minus (rugi), dengan kerugian terbesar bersumber dari produk Tables (Meja) di wilayah Central akibat diskon ugal-ugalan hingga 26,13%.

Rekomendasi : Perusahaan wajib membatasi diskon maksimal di angka 20%, memangkas promo di bulan sepi (Januari & April), serta mengalihkan anggaran diskon meja ke program loyalitas segmen Consumer pada produk teknologi.



6. MARKETING CAMPAIGN

Tujuan : Evaluasi efektivitas kombinasi saluran, tipe kampanye, dan target audiens pemasaran guna mengoptimalkan konversi iklan serta Return on Investment (ROI) perusahaan.

Hasil : Investasi iklan sebesar \$1,25 Miliar menghasilkan konversi stabil di 8,01%, di mana Email Marketing sukses menjadi saluran dengan ROI tertinggi sedangkan iklan jangka pendek di Instagram menghasilkan performa terburuk.

Rekomendasi : Hentikan iklan jangka pendek berbiaya murah di Instagram, pertahankan strategi iklan Display jangka panjang dengan biaya di atas \$5.000, serta perbaiki tampilan landing page untuk menekan 92% audiens yang rontok setelah klik iklan.



OVERVIEW PROJECT

7. PRODUCT ANALYSIS PERFORMANCE

Tujuan : Menganalisis performa bisnis e-commerce secara menyeluruh berdasarkan kontribusi produk terhadap revenue, biaya operasional logistik, dan kualitas performa pengiriman.

Hasil : Kategori Toys sukses menjadi motor penggerak utama revenue dengan transaksi credit card sebagai metode paling dominan, sementara kualitas logistik dinilai sangat sehat dengan 90,08% pesanan sampai tepat waktu.

Rekomendasi : Prioritaskan alokasi stok dan strategi promosi pada kategori Toys, lakukan perbaikan kemasan produk Furniture Decor untuk menekan biaya operasional pengiriman, serta luncurkan program retensi demi meningkatkan repeat purchase.




8. MARKET BASKET ANALYSIS

Tujuan : Memahami perilaku belanja pelanggan dan mengidentifikasi asosiasi antarproduk yang sering dibeli bersamaan untuk merumuskan strategi cross-selling dan product bundling yang efektif.

Hasil : Mayoritas ukuran keranjang belanja pelanggan tergolong kecil (2-4 produk) dengan Whole Milk bertindak sebagai anchor product yang paling mendominasi dan paling sering muncul di berbagai kombinasi transaksi.

Rekomendasi : Terapkan strategi product bundling atau penempatan promosi berdekatan antara Whole Milk dengan produk komoditas pendukung seperti Yogurt, Rolls/Buns, dan Other Vegetables guna mendorong kuantitas belanja per transaksi.




OVERVIEW PROJECT

9.DAIRY PRODUCT PERFORMANCE ANALYSIS

Tujuan : Menganalisis performa penjualan produk susu (dairy products) untuk mengidentifikasi produk dan merek penyumbang revenue terbesar, menilai efektivitas penjualan (Sell-Through Rate & Product Movement), serta menentukan prioritas strategi pertumbuhan bisnis.

Hasil : Performa bisnis dipacu utama oleh produk Curd dan Lassi (serta merek Amul dan Mother Dairy) yang mendominasi volume penjualan dan revenue di seluruh saluran distribusi, meskipun mayoritas produk masih tergolong Slow Moving.

Rekomendasi : Fokuskan pengalokasian stok, strategi promosi, dan optimalisasi rantai distribusi pada produk unggulan pendorong revenue utama—seperti Curd, Lassi, Paneer, dan Butter—sambil mengendalikan inventaris berbasis Sell-Through Rate agar perputaran barang tetap efisien.



PROBLEM STATEMENT

Dalam industri food delivery, ketepatan waktu pengiriman merupakan salah satu faktor utama yang memengaruhi kepuasan pelanggan dan kualitas layanan. Namun, waktu pengiriman dapat dipengaruhi oleh berbagai faktor, baik dari sisi operasional seperti jarak pengiriman, waktu persiapan pesanan, pengalaman kurir, dan jenis kendaraan, maupun faktor eksternal seperti kondisi lalu lintas dan cuaca. Keterlambatan pengiriman tidak hanya berdampak pada pengalaman pelanggan, tetapi juga dapat menurunkan efisiensi operasional perusahaan. Oleh karena itu, diperlukan analisis untuk mengidentifikasi faktor-faktor yang paling memengaruhi delivery time, memahami pola keterlambatan pada berbagai kondisi operasional, serta mengevaluasi kemampuan model prediktif dalam memperkirakan waktu pengiriman guna mendukung pengambilan keputusan yang lebih efektif.

01

Faktor-faktor apa yang paling memengaruhi delivery time dan bagaimana hubungan masing-masing faktor terhadap waktu pengiriman?

02

Bagaimana performa pengiriman berbeda berdasarkan kondisi operasional dan lingkungan, seperti traffic level, weather, time of day, vehicle type, serta courier experience?

03

Kondisi atau kombinasi faktor apa yang memiliki risiko keterlambatan tertinggi dan perlu menjadi prioritas perbaikan operasional?

04

Seberapa baik model machine learning dapat memprediksi delivery time dan faktor apa saja yang paling berpengaruh dalam model prediksi tersebut?

TUJUAN ANALYSIS

Melakukan analisis terhadap data food delivery untuk mengidentifikasi faktor-faktor yang memengaruhi waktu pengiriman, memahami pola keterlambatan, serta menghasilkan insight yang dapat digunakan untuk meningkatkan efisiensi operasional dan kualitas layanan pengiriman.

01

Mengidentifikasi pola dan tren delivery time berdasarkan karakteristik operasional dan lingkungan.

02

Menganalisis pengaruh faktor-faktor seperti traffic level, weather, distance, preparation time, vehicle type, dan courier experience terhadap delivery time.

03

Mengidentifikasi kondisi yang memiliki risiko keterlambatan tertinggi sehingga dapat menjadi fokus perbaikan operasional.

04

Mengevaluasi kemampuan model machine learning dalam memprediksi delivery time untuk mendukung estimasi waktu pengiriman yang lebih akurat.

05

Memberikan rekomendasi berbasis data untuk membantu pengambilan keputusan dan meningkatkan performa layanan pengiriman.

DATA UNDERSTANDING

Sumber Data

Kaggle

Jumlah Baris

1.000

Jumlah Kolom

9

Kolom	Keterangan	Tipe Data
Order_ID	Pengenal unik untuk setiap pesanan	Int64
Distance_km	Jarak pengiriman dalam kilometer	Float64
Weather	Kondisi cuaca saat pengiriman meliputi cerah, hujan, bersalju, berkabut, dan berangin	Object
Tranffic_Level	Kondisi lalu lintas yang dikategorikan sebagai rendah, sedang, atau tinggi	Object
Time_of_Day	Waktu untuk pengiriman dikategorikan pagi, siang, sore, dan malam	Object
Vehicle_Type	Jenis kendaraan yang digunakan untuk pengiriman, meliputi sepeda, skuter, dan mobil	Object
Preparation_Time_min	Waktu yang diperlukan untuk menyiapkan pesanan, dalam satuan menit	Int64
Courier_Experience_yrs	Pengalaman kurir dalam satuan tahun	Float64
Delivery_Time_min	Total waktu pengiriman dalam satuan menit (variable target)	Int64

DATA UNDERSTANDING

```
# Melihat ukuran data
df.shape
```

```
(1000, 9)
```

Struktur Data

Dataset mengenai food delivery times terdiri dari 1.000 **baris** data dan **9 kolom**

```
: Order_ID          int64
  Distance_km       float64
  Weather           object
  Traffic_Level     object
  Time_of_Day       object
  Vehicle_Type      object
  Preparation_Time_min int64
  Courier_Experience_yrs float64
  Delivery_Time_min int64
  dtvne: object
```

Type Data

Setelah mengecek terdapat untuk type data **sudah sesuai** pada semua kolom data

```
Distribusi Weather
Weather
Clear    470
Rainy    204
Foggy    103
Snowy     97
Windy     96
NaN       30
Name: count, dtype: int64

Distribusi Traffic_Level
Traffic_Level
Medium    390
Low       383
High      197
NaN        30
Name: count, dtype: int64
```

Cek Konsistensi Data

Tidak terdapat typo pada penulisan kolom kategori

```
[9]: # Mengecek jumlah nilai missing data
     df.isnull().sum()
```

```
[9]: Order_ID          0
     Distance_km       0
     Weather           30
     Traffic_Level     30
     Time_of_Day       30
     Vehicle_Type      0
     Preparation_Time_min 0
     Courier_Experience_yrs 30
     Delivery_Time_min 0
     dtvne: int64
```

Missing Value

Pada kolom dataset **terdapat missing value** yang perlu ditangani lebih lanjut

```
# Mengecek jumlah nilai duplikat
duplicate = df.duplicated().sum()
print(duplicate)
```


```
0
```

```
# mengecek duplicate order id
df['Order_ID'].duplicated().sum()

np.int64(0)
```

Duplicate Data

Setelah pengecekan **tidak terdapat data** yang **duplicate** antara baris kolom pada dataset.



Outlier Data

Terdapat 1 **kolom** yang memiliki nilai **outlier** tetapi ini normal karena banyak faktor yang mempengaruhi nilainya

DATA PREPARATION

HANDLING MISSING VALUE

Kolom Kategori

Menghandling missing value pada kolom kategori dengan mengisi **unknown** pada data yang missing



1. Menghandling missing value

a. Handling missing value kolom kategori

```
# Mengisi missing value untuk kolom kategori dengan unknown
cat_cols = ['Weather', 'Traffic_Level', 'Time_of_Day']

for col in cat_cols:
    df_clean[col] = df_clean[col].fillna('Unknown')

# Menampilkan jumlah data masing-masing kolom yang sudah di handling missingnya
cat_cols = ['Weather', 'Traffic_Level', 'Time_of_Day']

for col in cat_cols :
    print(f'\nDistribusi {col}')
    print(df_clean[col].value_counts(dropna=False))
```

Kolom Numerik

Menghandling kolom numerik dengan mengisi nilai **median** pada kolom yang missing



```
# menghandling missing value mengisi dengan nilai median
df_clean['Courier_Experience_yrs'] = df_clean['Courier_Experience_yrs'].fillna(
    df_clean['Courier_Experience_yrs'].median())
```


DATA PREPARATION

FEATURE ENGINEERING

DISTANCE CATEGORY

Kategori :

- Short = 0-5 km
- Medium = 5-10 km
- Long = 10-15 km
- Very long = 15-20 km



1. Menambahkan Distance Category

```
# Menambahkan kolom distance category
df_clean['Distance_Category'] = pd.cut(
    df_clean['Distance_km'],
    bins=[0,5,10,15,20],
    labels=[
        'Short',
        'Medium',
        'Long',
        'Very Long'
    ])

```

```
df_clean['Distance_Category'].value_counts()
```

```
Distance_Category
Long          260
Very Long     251
Short         248
Medium        241
Name: count, dtype: int64
```

DATA PREPARATION

FEATURE ENGINEERING

EXPERIENCE GROUP

Kategori :

- Junior = 0-2 tahun
- Mid-Level = 3-5 tahun
- Senior = 6-9 tahun



2. Menambahkan experience group

```
# Menambahkan kolom experience group
df_clean['Experience_Group'] = pd.cut(
    df_clean['Courier_Experience_yrs'],
    bins=[-1,2,5,9],
    labels=[
        'Junior',
        'Mid-Level',
        'Senior'
    ])

```

```
df_clean['Experience_Group'].value_counts()
```

```
Experience_Group
Senior      409
Junior      297
Mid-Level   294
Name: count, dtype: int64
```

DATA PREPARATION

FEATURE ENGINEERING

DELAY LEVEL

Kategori :

- 0-30 menit = Fast
- 31-60 menit = Normal
- 61-90 menit = Slow
- lebih dari 90 menit = Very Slow




3. Menambahkan kolom delay level

```
# Menambahkan kolom delay level
df_clean['Delay_Level'] = pd.cut(
    df_clean['Delivery_Time_min'],
    bins=[0,30,60,90,200],
    labels=[
        'Fast',
        'Normal',
        'Slow',
        'Very Slow'
    ])
```

```
df_clean['Delay_Level'].value_counts()
```

```
Delay_Level
Normal      467
Slow        340
Fast         118
Very Slow    75
Name: count, dtype: int64
```


EXPLORATORY DATA ANALYST (EDA)



INTERPRETASI

- Distance_km : uniform → Jarak pengiriman tersebar cukup merata di rentang 0 hingga 20 km.
- Preparation time min : uniform → Waktu penyiapan barang/makanan berkisar dari 5 hingga 30 menit.
- Courier experience yrs : bimodal/rata → Pengalaman kurir mencakup rentang 0 hingga 9 tahun.
- Delivery time min : miring ke kanan → Mayoritas pengiriman membutuhkan waktu antara 40 hingga 80 menit (puncak tertinggi ada di rentang 45–70 menit).


EXPLORATORY DATA ANALYST (EDA)



INTERPRETASI

1. Weather (cuaca)
 - Saat proses pengiriman barang cuaca dominan cerah dan cuaca hujan di posisi kedua
2. Traffic Level (tingkat lalu lintas)
 - Sebagian besar pengiriman terjadi pada kondisi medium dan low traffic
3. Time of day (waktu pengiriman)
 - Jam operasional aktif terbagi cukup merata pada pagi, sore, dan siang hari. Serta pengiriman paling sedikit terjadi pada malam hari
4. Vehicle type (jenis kendaraan)
 - Motor menjadi transportasi utama yang digunakan dalam pengiriman barang
5. Distance category (kategori jarak)
 - Serabannya sangat merata (uniform), semua kategori jarak memiliki frekuensi yang hampir identik atau sama
6. Experience group (Pengalaman kurir)
 - Kurir tingkat senior menjadi kelompok paling banyak
7. Delay level (Tingkat keterlambatan)
 - Sebagian besar pengiriman berjalan normal atau agak terlambat. Pengiriman kategori sangat cepat dan sangat lambat memiliki frekuensi yang relatif kecil

EXPLORATORY DATA ANALYST (EDA)



INTERPRETASI

Matriks pairplot menunjukkan bahwa dari seluruh variabel fitur, hanya jarak (Distance_km) yang memiliki korelasi positif linear yang signifikan terhadap waktu pengiriman (Delivery_Time_min), di mana durasi pengiriman secara konsisten meningkat seiring bertambahnya jarak. Sementara itu, variabel waktu penyiapan (Preparation_Time_min) dan pengalaman kurir (Courier_Experience_yrs) menunjukkan sebaran titik yang cenderung acak tanpa pola linear yang jelas terhadap Delivery_Time_min maupun terhadap variabel lainnya. Secara keseluruhan, pairplot ini mengonfirmasi bahwa jarak tempuh merupakan prediktor utama bagi durasi pengiriman, sedangkan fitur lainnya independen satu sama lain.



DASHBOARD VISUALISASI FOOD DELIVERY TIMES



DELIVERY PERFORMANCE OVERVIEW



INSIGHT

Analisis menunjukkan bahwa traffic level merupakan faktor yang paling berpengaruh terhadap waktu pengiriman, di mana kondisi lalu lintas yang lebih padat menghasilkan delivery time yang lebih tinggi dibandingkan kondisi lalu lintas normal. Selain itu, cuaca buruk seperti Snowy dan Foggy juga berkontribusi terhadap peningkatan waktu pengiriman, menunjukkan bahwa faktor eksternal memiliki dampak yang signifikan terhadap performa layanan.

INSIGHT


Visualisasi scatter plot menunjukkan adanya hubungan positif antara Distance_km dan Delivery_Time_min, yang berarti semakin jauh jarak pengiriman maka semakin lama waktu yang dibutuhkan untuk menyelesaikan pesanan.

INSIGHT

hubungan antara Preparation_Time_min dan Delivery_Time_min, yang menunjukkan bahwa keterlambatan tidak hanya dipengaruhi oleh proses pengiriman, tetapi juga oleh waktu yang dibutuhkan restoran untuk menyiapkan pesanan.

INSIGHT

- Kurir dengan pengalaman lebih tinggi cenderung memiliki delivery time yang lebih rendah.
- Jenis kendaraan tidak menunjukkan perbedaan signifikan terhadap performa pengiriman.
- Pengiriman pada malam hari memiliki rata-rata delivery time yang lebih rendah dibandingkan waktu lainnya.
- Kombinasi cuaca buruk dan traffic tinggi menghasilkan delivery time tertinggi serta menjadi kondisi dengan risiko keterlambatan terbesar.
- Sebagian besar pesanan berada pada kategori Normal dan Slow, menunjukkan masih adanya peluang peningkatan efisiensi operasional.



MECHINE LEARNING MODELING

	Model	MAE	RMSE	R2
0	Linear Regression	5.943546	8.804385	0.827058
1	Random Forest	7.107842	10.322154	0.762293

INTERPRETASI

- Model Linear Regression menjadi pilihan terbaik hal ini dikarena oleh hal berikut :
 - Nilai MAE linear regression lebih kecil
 - Nilai RMSE linear regression lebih kecil
 - Nilai R^2 linear regression lebih besar
- Linear regression mampu menjelaskan sekitar 82,7% variasi delivery time dan memberikan error prediksi yang lebih rendah dibandingkan random forest



INTERPRETASI

Scatter plot menunjukkan hubungan yang kuat antara nilai aktual dan nilai prediksi sehingga model mampu menangkap pola utama dalam data dengan baik

CONCLUSION & RECOMMENDATION

Traffic dan cuaca menjadi faktor utama keterlambatan pengiriman

Optimalkan rute pengiriman dan sesuaikan estimasi waktu pada kondisi traffic tinggi serta cuaca buruk untuk mengurangi risiko keterlambatan.

Distance dan preparation time memiliki hubungan langsung dengan delivery time

Percepat proses persiapan pesanan dan tingkatkan efisiensi pengelolaan pesanan jarak jauh untuk mempercepat pengiriman.

Model prediktif mampu memperkirakan delivery time dengan baik ($R^2 = 82,7\%$)

Manfaatkan model untuk meningkatkan akurasi estimasi pengiriman dan membantu pengambilan keputusan operasional secara proaktif.

DETAIL INFORMATION

LINK CANVA

CANVA FOOD
DELIVERY ANALYSIS

LINK GITHUB

GITHUB FOOD
DELIVERY ANALYSIS

LINK TABLEU PUBLIC

TABLEU PUBLIC
FOOD DELIVERY
ANALYSIS

The background is a dark teal color with a faint, out-of-focus image of a modern office interior. Overlaid on this are several semi-transparent white icons: a 4x4 grid of dots in the top left, a line graph with a bar chart at the bottom in the top center, a world map in the top right, and two smaller versions of the line graph and bar chart icon in the bottom left and bottom right. A large, rounded rectangular box with a white border is centered in the lower half of the image.

Thank you

for your attention!